FUNDAÇÃO GETULIO VARGAS
ESCOLA DE MATEMÁTICA APLICADA
Inferência Estatística

Tradução de Probability and Statistics by DeGroot & Schervish

VICTOR GABRIEL HARUO IWAMOTO

Rio de Janeiro – RJ
August 2025

1 O Golem de Praga

No século XVI, a Casa de Habsburgo controlava grande parte da Europa Central, os Países Baixos e a Espanha, bem como as colônias da Espanha nas Américas. A Casa era talvez a primeira verdadeira potência mundial. O Sol brilhava sempre sobre alguma porção dela. Seu governante era também o Imperador do Sacro Império Romano-Germânico, e sua sede de poder era Praga. O Imperador no final do século XVI, Rodolfo II, amava a vida intelectual. Ele investiu nas artes, nas ciências (incluindo astrologia e alquimia) e na matemática, tornando Praga um centro mundial de aprendizado e erudição. É apropriado, então, que nessa atmosfera erudita tenha surgido um robô primitivo, o Golem de Praga.

Um golem (GOH-lem) é um robô de argila do folclore judaico, construído a partir de poeira, fogo e água. Ele é trazido à vida ao inscrever-se *emet*, hebraico para "verdade", em sua testa. Animado pela verdade, mas carente de livre-arbítrio, um golem sempre faz exatamente o que lhe é dito. Isso é uma sorte, porque o golem é incrivelmente poderoso, capaz de suportar e realizar mais do que seus criadores poderiam. No entanto, sua obediência também traz perigo, pois instruções descuidadas ou eventos inesperados podem virar um golem contra seus criadores. Sua abundância de poder é igualada por sua falta de sabedoria.

Em algumas versões da lenda do golem, o Rabino Judah Loew ben Bezalel buscou uma maneira de defender os judeus de Praga. Como em muitas partes da Europa Central do século XVI, os judeus de Praga eram perseguidos. Usando técnicas secretas da *Kabbalah*, o Rabino Judah foi capaz de construir um golem, animá-lo com a "verdade"e ordená-lo a defender o povo judeu de Praga. Nem todos concordaram com a ação de Judah, temendo consequências indesejadas de brincar com o poder da vida. Por fim, Judah foi forçado a destruir o golem, pois sua combinação de poder extraordinário com desajeitamento acabou levando a mortes de inocentes. Apagando uma letra da inscrição *emet* para soletrar, em vez disso, *met*, "morte", o Rabino Judah desativou o robô.

1.1 Golems estatísticos

Os cientistas também fazem golems. Nossos golems raramente têm forma física, mas eles também são frequentemente feitos de argila, vivendo no silício como código de computador. Esses golems são modelos científicos. Mas esses golems têm efeitos reais no mundo, por meio das previsões que fazem e das intuições que desafiam ou inspiram. Uma preocupação com a "verdade"anima esses modelos, mas assim como um golem ou um robô moderno, os modelos científicos não são nem verdadeiros nem falsos, nem profetas nem charlatães. Em vez disso, são construtos projetados para algum propósito. Esses construtos são incrivelmente poderosos, conduzindo obedientemente seus cálculos programados.

Às vezes, sua lógica implacável revela implicações anteriormente ocultas para seus criadores. Essas implicações podem ser descobertas inestimáveis. Ou podem produzir comportamentos tolos e perigosos. Em vez de anjos idealizados da razão, os modelos científicos são poderosos robôs de argila sem intenção própria,

avançando desajeitadamente de acordo com as instruções míopes que incorporam. Como o golem do Rabino Judah, os golems da ciência são sabiamente vistos com admiração e apreensão. Nós absolutamente temos que usá-los, mas fazê-lo sempre acarreta algum risco.

Existem muitos tipos de modelos estatísticos. Sempre que alguém utiliza até mesmo um procedimento estatístico simples, como um teste t clássico, ela está implantando um pequeno golem que executará obedientemente um cálculo exato, realizando-o da mesma maneira (quase) todas as vezes, sem reclamar. Quase todos os ramos da ciência dependem dos sentidos dos golems estatísticos. Em muitos casos, não é mais possível sequer medir fenômenos de interesse sem fazer uso de um modelo. Para medir a força da seleção natural, a velocidade de um neutrino ou o número de espécies na Amazônia, devemos usar modelos. O golem é uma prótese, fazendo a medição para nós, realizando cálculos impressionantes, encontrando padrões onde nenhum é óbvio.

No entanto, não há sabedoria no golem. Ele não discerne quando o contexto é inadequado para suas respostas. Ele apenas conhece seu próprio procedimento, nada mais. Ele apenas faz o que lhe é dito.

E assim continua sendo um triunfo da ciência estatística que existam agora tantos golems diversos, cada um útil em um contexto particular. Visto dessa forma, a estatística não é matemática nem ciência, mas sim um ramo da engenharia. E, como a engenharia, um conjunto comum de princípios de design e restrições produz uma grande diversidade de aplicações especializadas.

Essa diversidade de aplicações ajuda a explicar por que os cursos introdutórios de estatística são tão frequentemente confusos para os iniciantes. Em vez de um único método para construir, refinar e criticar modelos estatísticos, os alunos recebem um zoológico de golems pré-construídos conhecidos como "testes". Cada teste tem um propósito específico. Árvores de decisão, como a da FIGURA 1.1, são comuns. Respondendo a uma série de perguntas sequenciais, os usuários escolhem o procedimento "correto"para as circunstâncias de sua pesquisa.

Infelizmente, embora estatísticos experientes compreendam a unidade desses procedimentos, estudantes e pesquisadores raramente o fazem. Cursos avançados de estatística enfatizam princípios de engenharia, mas a maioria dos cientistas nunca chega tão longe. Ensinar estatística dessa forma é um pouco como ensinar engenharia de trás para frente, começando com a construção de pontes e terminando com a física básica. Assim, estudantes e muitos cientistas tendem a usar gráficos como a FIGURA 1.1 sem pensar muito em sua estrutura subjacente, sem muita consciência dos modelos que cada procedimento incorpora e sem qualquer estrutura para ajudá-los a fazer os compromissos inevitáveis exigidos pela pesquisa real. Não é culpa deles.

Para alguns, a caixa de ferramentas de golems pré-fabricados é tudo de que precisarão. Desde que permaneçam dentro de contextos bem testados, usando apenas alguns procedimentos diferentes em tarefas apropriadas, muita ciência boa pode ser concluída. Isso é semelhante a como encanadores podem fazer muito trabalho útil sem saber muito sobre dinâmica de fluidos. O problema sério começa quando os estudiosos passam a conduzir pesquisas inovadoras,

expandindo as fronteiras de suas especialidades. É como se obtivéssemos nossos engenheiros hidráulicos promovendo encanadores.

Por que os testes não são suficientes para a pesquisa? Os procedimentos clássicos da estatística introdutória tendem a ser inflexíveis e frágeis. Por inflexíveis, quero dizer que eles têm formas muito limitadas de se adaptar a contextos de pesquisa únicos. Por frágeis, quero dizer que eles falham de maneiras imprevisíveis quando aplicados a novos contextos. Isso importa, porque nas fronteiras da maioria das ciências, raramente está claro qual procedimento é apropriado. Nenhum dos golems tradicionais foi avaliado em novos cenários de pesquisa, e por isso pode ser difícil escolher um e depois entender como ele se comporta. Um bom exemplo é o *teste exato de Fisher*, que se aplica (exatamente) a um contexto empírico extremamente estreito, mas é regularmente usado sempre que as contagens de células são pequenas. Eu pessoalmente li centenas de usos do teste exato de Fisher em revistas científicas, mas, além do uso original de Fisher, nunca o vi ser usado adequadamente. Mesmo um procedimento como a regressão linear ordinária, que é bastante flexível de muitas maneiras, sendo capaz de codificar uma grande diversidade de hipóteses interessantes, às vezes é frágil. Por exemplo, se houver um erro substancial de medição nas variáveis de predição, o procedimento pode falhar de maneiras espetaculares. Mas, mais importante, quase sempre é possível fazer melhor do que a regressão linear ordinária, em grande parte devido a um fenômeno conhecido como OVERFITTING (Capítulo 7).

O ponto não é que as ferramentas estatísticas sejam especializadas. Claro que são. O ponto é que as ferramentas clássicas não são diversas o suficiente para lidar com muitas questões comuns de pesquisa. Toda área ativa da ciência lida com dificuldades únicas de medição e interpretação, conversa com teorias idiossincráticas em um dialeto mal compreendido por cientistas de outras tribos. Especialistas em estatística fora da disciplina podem ajudar, mas eles são limitados pela falta de fluência nas preocupações empíricas e teóricas da disciplina.

Além disso, nenhuma ferramenta estatística faz nada por conta própria para abordar o problema básico de inferir causas a partir de evidências. Golems estatísticos não entendem causa e efeito. Eles apenas entendem associação. Sem nossa orientação e ceticismo, golems pré-fabricados podem não fazer nada de útil. Pior, eles podem destruir Praga.

O que os pesquisadores precisam é de alguma teoria unificada de engenharia de golems, um conjunto de princípios para projetar, construir e refinar procedimentos estatísticos de propósito específico. Todo grande ramo da filosofia estatística possui tal teoria unificada. Mas a teoria nunca é ensinada em cursos introdutórios — e frequentemente nem mesmo em avançados. Portanto, há benefícios em repensar a inferência estatística como um conjunto de estratégias, em vez de um conjunto de ferramentas pré-fabricadas.

1.2 Repensar estatístico

Muita coisa pode dar errado com a inferência estatística, e esta é uma das razões pelas quais os iniciantes ficam tão ansiosos com ela. Quando a estrutura

consiste em escolher um teste pré-fabricado em um fluxograma, a ansiedade pode aumentar à medida que se teme não escolher o teste "correto". Os estatísticos, por sua vez, podem sentir prazer em repreender os cientistas, piorando a batalha psicológica.

Mas a ansiedade pode ser cultivada em sabedoria. Essa é a razão pela qual este livro insiste em trabalhar com os detalhes computacionais de cada golem. Se você não entende como o golem processa a informação, não pode interpretar a saída do golem. Isso requer conhecer o modelo estatístico em maior detalhe do que o habitual, e requer fazer os cálculos do jeito difícil, pelo menos até que você seja sábio o suficiente para usar as soluções de apertar um botão.

Existem obstáculos conceituais também, obstáculos relacionados a como os estudiosos definem os objetivos estatísticos e interpretam os resultados estatísticos. Entender qualquer golem individual não é suficiente nesses casos. Em vez disso, precisamos de alguma epistemologia estatística, uma apreciação de como os modelos estatísticos se relacionam com as hipóteses e com os mecanismos naturais de interesse. Afinal, o que se supõe que estejamos fazendo com essas pequenas máquinas computacionais?

O maior obstáculo que encontro entre alunos e colegas é a crença tácita de que o objetivo adequado da inferência estatística é testar hipóteses nulas. Este é o objetivo correto, diz o pensamento, porque Karl Popper argumentou que a ciência avança ao falsificar hipóteses. Karl Popper (1902–1994) é possivelmente o filósofo da ciência mais influente, pelo menos entre os cientistas. Ele argumentou persuasivamente que a ciência funciona melhor ao desenvolver hipóteses que são, em princípio, falsificáveis. Buscar evidências que possam embaraçar nossas ideias é um padrão normativo, e ao qual a maioria dos estudiosos — quer se descrevam como cientistas ou não — adere. Então, talvez os procedimentos estatísticos devessem falsificar hipóteses, se desejamos ser bons cientistas estatísticos.

Mas o que foi dito acima é um tipo de Popperismo folclórico, uma filosofia informal da ciência comum entre cientistas, mas não entre filósofos da ciência. A ciência não é descrita pelo padrão de falsificação, e Popper reconheceu isso. De fato, a falsificação dedutiva é impossível em quase todos os contextos científicos. Nesta seção, reviso duas razões para essa impossibilidade.

1. **Hipóteses não são modelos.** As relações entre hipóteses e diferentes tipos de modelos são complexas. Muitos modelos correspondem à mesma hipótese, e muitas hipóteses correspondem a um único modelo. Isso torna a falsificação estrita impossível.

2. **A medição importa.** Mesmo quando pensamos que os dados falsificam um modelo, outro observador debaterá nossos métodos e medidas. Eles não confiam nos dados. Às vezes, eles estão certos.

Por ambas as razões, a falsificação dedutiva nunca funciona. O método científico não pode ser reduzido a um procedimento estatístico, e por isso nossos métodos estatísticos não devem fingir que podem. A evidência estatística é parte da grande bagunça que é a ciência, com todo o seu combate, egotismo e coerção

mútua. Se você acredita, como eu, que a ciência muitas vezes funciona, então aprender que ela não funciona por meio da falsificação não deve mudar sua opinião. Mas pode ajudá-lo a fazer ciência melhor, pois abrirá seus olhos para muitas funções legitimamente úteis dos golems estatísticos.

> **Repensando: O NHST é falsificacionista?** O teste de significância de hipótese nula, NHST (*Null hypothesis significance testing*), é frequentemente identificado com a filosofia da ciência falsificacionista, ou Popperiana. No entanto, geralmente o NHST é usado para falsificar uma hipótese nula, não a hipótese de pesquisa real. Portanto, a falsificação está sendo feita em algo diferente do modelo explicativo. Isso parece o inverso da filosofia de Karl Popper.

1.2.1 Hipóteses não são modelos

Quando tentamos falsificar uma hipótese, devemos trabalhar com um modelo de algum tipo. Mesmo quando a tentativa não é explicitamente estatística, há sempre um modelo tácito de medição, de evidência, que operacionaliza a hipótese. Todos os modelos são falsos, então o que significa falsificar um modelo? Uma consequência da exigência de trabalhar com modelos é que não é mais possível deduzir que uma hipótese é falsa, apenas porque rejeitamos um modelo derivado dela.

Vamos explorar essa consequência no contexto de um exemplo da biologia populacional (FIGURA 1.2). Começando na década de 1960, biólogos evolucionistas se interessaram pela proposta de que a maioria das mudanças evolutivas na frequência gênica é causada não pela seleção natural, mas sim por mutação e deriva. Ninguém realmente duvidava que a seleção natural fosse responsável pelo design funcional. Este era um debate sobre sequências genéticas. Assim começaram várias décadas produtivas de combate acadêmico sobre modelos "neutros"de evolução molecular. Esse combate está mais fortemente associado a Motoo Kimura (1924–1994), que talvez tenha sido o mais forte defensor dos modelos neutros. Mas muitos outros geneticistas de populações participaram. Com o passar do tempo, disciplinas relacionadas como ecologia de comunidades e antropologia experimentaram (ou estão experimentando atualmente) suas próprias versões do debate da neutralidade.

Vamos usar o esquema na FIGURA 1.2 para explorar conexões entre hipóteses motivadoras e diferentes modelos, no contexto do debate da evolução neutra. À esquerda, há duas hipóteses estereotipadas e informais: Ou a evolução é "neutra"(H_0) ou a seleção natural importa de alguma forma (H_1). Essas hipóteses têm limites vagos, porque começam como conjecturas verbais, não modelos precisos. Existem milhares de processos detalhados possíveis que podem ser descritos como "neutros", dependendo das escolhas sobre, por exemplo, estrutura populacional, número de locais, número de alelos em cada local, taxas de mutação e recombinação.

Uma vez feitas essas escolhas, temos a coluna do meio na FIGURA 1.2, os MODELOS DE PROCESSO detalhados de evolução. P_{0A} e P_{0B} diferem no fato de

que um assume que o tamanho e a estrutura da população têm sido constantes por tempo suficiente para que a distribuição de alelos atinja um estado estacionário. O outro imagina, em vez disso, que o tamanho da população flutua ao longo do tempo, o que pode ser verdade mesmo quando não há diferença seletiva entre os alelos. A hipótese "a seleção importa" H_1 da mesma forma corresponde a muitos modelos de processo diferentes. Mostrei dois grandes protagonistas: um modelo no qual a seleção sempre favorece certos alelos e outro no qual a seleção flutua ao longo do tempo, favorecendo diferentes alelos.

Uma característica importante desses modelos de processo é que eles expressam uma estrutura causal. Diferentes modelos de processo formalizam diferentes relações de causa e efeito. Quer analisada matematicamente ou por simulação, a direção do tempo em um modelo significa que algumas coisas causam outras, mas não o inverso. Você pode usar tais modelos para realizar experimentos e investigar suas implicações causais. Às vezes, essas investigações revelam, antes mesmo de passarmos para a inferência estatística, que o modelo não pode explicar um fenômeno de interesse.

Para desafiar os modelos de processo com dados, eles precisam ser transformados em modelos estatísticos. Infelizmente, os modelos estatísticos não incorporam relações causais específicas. Um modelo estatístico expressa associações entre variáveis. Como resultado, muitos modelos de processo diferentes podem ser consistentes com qualquer modelo estatístico único.

Como obtemos um modelo estatístico a partir de um modelo causal? Uma maneira é derivar a distribuição de frequência esperada de alguma quantidade — uma "estatística"— a partir do modelo causal. Por exemplo, uma estatística comum neste contexto é a distribuição de frequência (histograma) da frequência de diferentes variantes genéticas (alelos). Alguns alelos são raros, aparecendo em apenas alguns indivíduos. Outros são muito comuns, aparecendo em muitos indivíduos na população. Um resultado famoso na genética de populações é que um modelo como P_{0A} produz uma distribuição de *lei de potência* das frequências alélicas. E assim esse fato produz um modelo estatístico, M_{II}, que prevê uma lei de potência nos dados. Em contraste, o modelo de processo de seleção constante P_{1A} prevê algo bem diferente, M_{III}.

Infelizmente, outros modelos de seleção (P_{1B}) implicam o mesmo modelo estatístico, M_{II}, que o modelo neutro. Eles também produzem leis de potência. Então chegamos à lição desconfortável:

1. Qualquer modelo estatístico (M) dado pode corresponder a mais de um modelo de processo (P).

2. Qualquer hipótese (H) dada pode corresponder a mais de um modelo de processo (P).

3. Qualquer modelo estatístico (M) dado pode corresponder a mais de uma hipótese (H).

Agora veja o que acontece quando comparamos os modelos estatísticos aos dados. A abordagem clássica é tomar o modelo "neutro"como uma hipótese

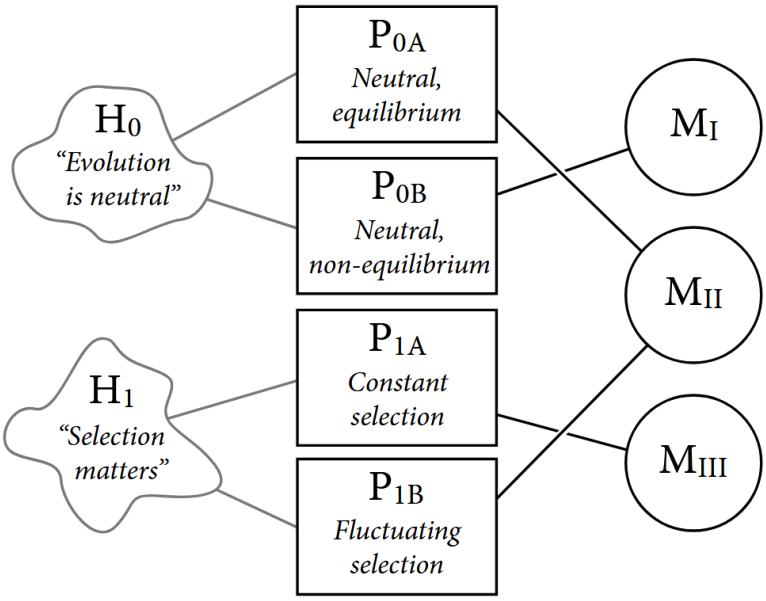

Figura 1: Relações entre hipóteses (esquerda), modelos de processo detalhados (meio) e modelos estatísticos (direita), ilustrados pelo exemplo de modelos "neutros"de evolução. As hipóteses (H) são tipicamente vagas e, portanto, correspondem a mais de um modelo de processo (P). As avaliações estatísticas de hipóteses raramente abordam os modelos de processo diretamente. Em vez disso, elas dependem de modelos estatísticos (M), os quais refletem apenas alguns aspectos dos modelos de processo. Como resultado, as relações são múltiplas em ambas as direções: Hipóteses não implicam modelos únicos, e modelos não implicam hipóteses únicas. Esse fato complica enormemente a inferência estatística.

nula. Se os dados não forem suficientemente semelhantes à expectativa sob a nula, então dizemos que "rejeitamos"a hipótese nula. Suponha que sigamos o histórico deste assunto e tomemos P_{0A} como nossa hipótese nula. Isso implica dados correspondentes a M_{II}. Mas como o mesmo modelo estatístico corresponde a um modelo de seleção P_{1B}, não está nem um pouco claro o que devemos fazer em relação a rejeitar ou aceitar a nula. O modelo nulo não é único para nenhum modelo de processo nem hipótese. Se rejeitarmos a nula, não podemos realmente concluir que a seleção importa, porque existem outros modelos neutros que preveem distribuições diferentes de alelos. E se falharmos em rejeitar a nula, não podemos realmente concluir que a evolução é neutra, porque alguns modelos de seleção esperam a mesma distribuição de frequência.

Este é um grande incômodo. Uma vez que temos o diagrama na FIGURA 1.2, é fácil ver o problema. Mas poucos de nós têm tanta sorte. Enquanto a genética de populações reconheceu esse problema, acadêmicos em outras disciplinas continuam a testar distribuições de frequência contra as expectativas da lei de potência, argumentando até mesmo que existe apenas um modelo neutro. Mesmo que houvesse apenas um modelo neutro, existem tantos modelos não neutros que imitam as previsões da neutralidade, que nem rejeitar nem falhar em rejeitar o modelo nulo carrega muito poder inferencial.

Então o que pode ser feito? Bem, se você tem múltiplos modelos de processo, muita coisa pode ser feita. Se acontece que todos os modelos de processo de interesse fazem previsões muito semelhantes, então você sabe que deve procurar uma descrição diferente da evidência, uma descrição sob a qual os processos pareçam diferentes. Por exemplo, embora P_{0A} e P_{1B} façam previsões de lei de potência muito semelhantes para a distribuição de frequência de alelos, eles fazem previsões muito diferentes para a distribuição de mudanças na frequência alélica ao longo do tempo. Compare explicitamente as previsões de mais de um modelo e você pode se salvar de alguns tipos comuns de loucura.

Os modelos estatísticos também podem ser confundidos de outras maneiras, como a confusão causada por variáveis não observadas e viés de amostragem. Modelos de processo nos permitem projetar modelos estatísticos com esses problemas em mente. O modelo estatístico por si só não é suficiente.

> **Repensando: Entropia e identificação do modelo.** Uma razão pela qual os modelos estatísticos correspondem rotineiramente a muitos modelos de processo detalhados diferentes é porque eles dependem de distribuições como a normal, binomial, Poisson e outras. Essas distribuições são membros de uma família, a FAMÍLIA EXPONENCIAL. A natureza ama os membros desta família. A natureza os ama porque a natureza ama a entropia, e todas as distribuições da família exponencial são distribuições de ENTROPIA MÁXIMA. Tirar a personificação natural dessa explicação terá que esperar até o Capítulo 10. A implicação prática é que não se pode inferir o processo evolutivo a partir de uma lei de potência mais do que se pode inferir o processo de desenvolvimento a partir do fato de que a altura é normalmente distribuída. Esse fato deve nos tornar humildes

> sobre o que modelos típicos de regressão — o cerne deste livro — podem nos ensinar sobre processos mecanísticos. Por outro lado, a natureza de entropia máxima dessas distribuições significa que podemos usá-las para fazer trabalho estatístico útil, mesmo quando não conseguimos identificar o processo subjacente. Não apenas não podemos identificá-lo, mas também não precisamos.

1.2.2 A medição importa

A lógica da falsificação é muito simples. Temos uma hipótese H, e mostramos que ela implica alguma observação D. Então procuramos por D. Se não a encontrarmos, devemos concluir que H é falsa. Os lógicos chamam esse tipo de raciocínio de *modus tollens*, que é uma abreviação em latim para "o método de destruição". Em contraste, encontrar D não nos diz nada certo sobre H, porque outras hipóteses também podem prever D.

Uma fábula científica convincente que emprega o *modus tollens* diz respeito à cor dos cisnes. Antes de descobrir a Austrália, todos os cisnes que qualquer europeu já tinha visto tinham penas brancas. Isso levou à crença de que todos os cisnes são brancos. Vamos chamar isso de uma hipótese formal:

$$H_0 : \text{Todos os cisnes são brancos.}$$

Quando os europeus chegaram à Austrália, no entanto, eles encontraram cisnes com penas pretas. Essa evidência pareceu provar instantaneamente que H_0 era falsa. De fato, nem todos os cisnes são brancos. Alguns são certamente pretos, de acordo com todos os observadores. A principal percepção aqui é que, antes de viajar para a Austrália, nenhum número de observações de cisnes brancos poderia provar que H_0 era verdadeira. No entanto, exigiu-se apenas uma observação de um cisne negro para provar que era falsa.

Esta é uma história sedutora. Se podemos acreditar que hipóteses científicas importantes podem ser declaradas desta forma, então temos um método poderoso para melhorar a precisão de nossas teorias: procurar evidências que desconfirmem nossas hipóteses. Sempre que encontramos um cisne negro, H_0 deve ser falsa. Progresso!

Buscar evidências desconfirmadoras é importante, mas não pode ser tão poderoso quanto a história do cisne faz parecer. Além dos problemas de correspondência entre hipóteses e modelos, discutidos na seção anterior, a maioria dos problemas que os cientistas enfrentam não são tão logicamente discretos. Em vez disso, frequentemente enfrentamos dois problemas simultâneos que tornam a fábula do cisne não representativa. Primeiro, as observações são propensas a erros, especialmente nas fronteiras do conhecimento científico. Segundo, a maioria das hipóteses é quantitativa, referindo-se a graus de existência, em vez de discretas, referindo-se à presença ou ausência total. Vamos considerar brevemente cada um desses problemas.

1.2.3 Erro de observação

Todos os observadores concordarão sob a maioria das condições que um cisne é preto ou branco. Existem poucos tons intermediários, e os olhos da maioria dos observadores funcionam de maneira semelhante o suficiente para que haja pouca, se alguma, discordância sobre quais cisnes são brancos e quais são pretos. Mas esse tipo de exemplo dificilmente é comum na ciência, pelo menos em campos maduros. Em vez disso, rotineiramente confrontamos contextos em que não temos certeza se detectamos um resultado desconfirmador. Nas fronteiras do conhecimento científico, a capacidade de medir um fenômeno hipotético muitas vezes está tão em questão quanto o próprio fenômeno.

Aqui estão dois exemplos.

Em 2005, uma equipe de ornitólogos de Cornell alegou ter evidências de um indivíduo de Pica-pau-bico-de-marfim (*Campephilus principalis*), uma espécie que se pensava estar extinta. A hipótese implícita aqui é:

$$H_0 : \text{O Pica-pau-bico-de-marfim está extinto.}$$

Seria necessária apenas uma observação para falsificar essa hipótese. No entanto, muitos duvidaram da evidência. Apesar dos extensos esforços de busca e de uma recompensa em dinheiro de US$ 50.000 por informações que levassem a um espécime vivo, nenhuma evidência que satisfaça a todas as partes emergiu até agora (em 2015). Mesmo que surjam boas evidências físicas eventualmente, este episódio deve servir como um contraponto à história do cisne. Encontrar casos desconfirmadores é complicado pelas dificuldades de observação. Cisnes negros nem sempre são realmente cisnes negros, e às vezes cisnes brancos são na verdade cisnes negros. Existem confirmações equivocadas (falsos positivos) e desconfirmações equivocadas (falsos negativos). Contra esse pano de fundo de dificuldades de medição, os cientistas que já acreditam que o Pica-pau-bico-de-marfim está extinto sempre suspeitarão de uma alegação de falsificação. Aqueles que acreditam que ele ainda está vivo tenderão a contar a evidência mais vaga como falsificação.

Outro exemplo, este da física, concentra-se na detecção de neutrinos mais rápidos que a luz (*faster-than-light* - FTL). Em setembro de 2011, uma grande e respeitada equipe de físicos anunciou a detecção de neutrinos — pequenas partículas subatômicas neutras capazes de passar fácil e inofensivamente pela maior parte da matéria — que viajaram da Suíça para a Itália em um tempo ligeiramente superior à velocidade da luz. De acordo com Einstein, os neutrinos não podem viajar mais rápido que a velocidade da luz. Portanto, isso parece ser uma falsificação da relatividade restrita. Se for, viraria a física de cabeça para baixo.

A reação dominante da comunidade de física não foi "Einstein estava errado!", mas sim "Como a equipe estragou a medição?". A equipe que fez a medição teve a mesma reação, e pediu a outros que verificassem seus cálculos e tentassem replicar o resultado.

O que poderia dar errado na medição? Você pode pensar que medir a velocidade é uma simples questão de dividir a distância pelo tempo. E é, na escala

e na energia em que você vive. Mas com uma partícula fundamental como um neutrino, se você mede quando ela inicia sua jornada, você interrompe a jornada. A partícula é consumida pela medição. Portanto, são necessárias abordagens mais sutis. A diferença detectada em relação à velocidade da luz, além disso, é bastante pequena, e por isso até mesmo a latência do tempo que leva para um sinal viajar de um detector até uma sala de controle pode ser ordens de grandeza maior. E como a "medição"neste caso é na verdade uma estimativa de um modelo estatístico, todas as suposições do modelo agora são suspeitas. Em 2013, a comunidade de física foi unânime em afirmar que o resultado do neutrino FTL foi um erro de medição. Eles encontraram o erro técnico, que envolvia um cabo mal conectado. Além disso, os neutrinos cronometrados de eventos de supernova são consistentes com Einstein, e essas distâncias são muito maiores e, portanto, revelariam diferenças de velocidade muito melhores.

Tanto no drama do pica-pau quanto no do neutrino, o principal dilema é se a falsificação é real ou espúria. A medição é complicada em ambos os casos, mas de maneiras bem diferentes, tornando plausíveis tanto a detecção verdadeira quanto a detecção falsa. O próprio Popper estava ciente dessa limitação inerente à medição, e pode ser uma das razões pelas quais o próprio Popper via a ciência como algo mais amplo que a falsificação. Mas a natureza probabilística da evidência raramente aparece quando cientistas em atividade discutem a filosofia e a prática da falsificação. Minha leitura da história da ciência é que esses tipos de problemas de medição são a norma, não a exceção.

1.2.4 Hipóteses contínuas

Outro problema para a história do cisne é que a maioria das hipóteses científicas interessantes não é do tipo "todos os cisnes são brancos", mas sim do tipo:

$$H_0 : 80\% \text{ dos cisnes são brancos.}$$

Ou talvez:

$$H_0 : \text{Cisnes negros são raros.}$$

Agora o que devemos concluir, após observar um cisne negro? A hipótese nula não diz que cisnes negros não existem, mas sim que eles têm alguma frequência. A tarefa aqui não é provar ou desprovar uma hipótese desse tipo, mas sim estimar e explicar a distribuição da coloração dos cisnes com a maior precisão possível. Mesmo quando não há erro de medição de nenhum tipo, este problema nos impedirá de aplicar a história do cisne *modus tollens* à nossa ciência.

Você pode argumentar que a hipótese acima simplesmente não é uma boa hipótese científica, porque não é fácil de refutar. Mas se esse for o caso, então a maioria das questões importantes sobre o mundo não são boas hipóteses científicas. Nesse caso, deveríamos concluir que a definição de uma "boa hipótese"não está nos fazendo muito bem. Hoje, quase todo mundo concorda que é uma boa prática projetar experimentos e observações que possam diferenciar hipóteses concorrentes. Mas em muitos casos, a comparação deve ser probabilística, uma questão de grau, não de tipo.

1.2.5 A falsificação é consensual

A comunidade científica chega a considerar algumas hipóteses como falsas. A teoria calórica do calor e o modelo geocêntrico do universo não são mais ensinados em cursos de ciências, a menos que seja para ensinar como eles foram falsificados. E a evidência frequentemente — mas não sempre — tem algo a ver com tal falsificação.

Mas a falsificação é sempre *consensual*, não *lógica*. À luz dos reais problemas de erro de medição e da natureza contínua dos fenômenos naturais, as comunidades científicas discutem em direção a um consenso sobre o significado das evidências. Esses argumentos podem ser confusos. Após o fato, alguns livros didáticos deturpam a história para que pareça uma falsificação lógica. Tal revisionismo histórico pode prejudicar a todos. Pode prejudicar os cientistas, tornando impossível que o seu próprio trabalho corresponda às lendas que os precedem. Pode tornar a ciência um alvo fácil, ao promover um modelo de epistemologia científica facilmente atacável. E pode prejudicar o público, ao exagerar a definitividade do conhecimento científico.

1.3 Ferramentas para engenharia de golems

Portanto, se a tentativa de imitar a falsificação não é uma abordagem geralmente útil para os métodos estatísticos, o que devemos fazer? Devemos modelar. Modelos podem ser transformados em procedimentos de teste — todos os testes estatísticos também são modelos —, mas também podem ser usados para projetar, prever e argumentar. Fazer pesquisa se beneficia da capacidade de produzir e manipular modelos, tanto porque os problemas científicos são mais gerais do que "testar"quanto porque os golems pré-fabricados que você talvez tenha encontrado em cursos introdutórios de estatística são inadequados para muitos contextos de pesquisa. Você pode nem mesmo saber qual modelo estatístico usar, a menos que tenha um modelo generativo adicionalmente.

Se você quiser reduzir suas chances de destruir Praga, então é necessário algum *know-how* de engenharia de golems. Não se engane: você destruirá Praga eventualmente. Mas se você for um bom engenheiro de golems, pelo menos notará a destruição. E como você saberá muito sobre como seu golem funciona, terá uma boa chance de descobrir o que deu errado. Então seu próximo golem não será tão ruim. Sem o treinamento em engenharia, você estará sempre à mercê de outra pessoa.

Queremos usar nossos modelos para vários propósitos distintos: projetar a investigação, extrair informações dos dados e fazer previsões. Neste livro, escolhi focar em ferramentas que ajudam em cada propósito. Essas ferramentas são:

1. Análise de dados bayesiana
2. Comparação de modelos
3. Modelos multinível
4. Modelos causais gráficos

Essas ferramentas estão profundamente relacionadas umas com as outras, então faz sentido ensiná-las juntas. A compreensão dessas ferramentas vem, como sempre, apenas com a implementação — você não pode compreender a engenharia de golems até fazê-la. E por isso este livro se concentra principalmente no código, em como fazer as coisas. Mas no restante deste capítulo, forneço introduções a essas ferramentas.

1.3.1 Análise de dados bayesiana

Supondo que você tenha alguns dados, como deve usá-los para aprender sobre o mundo? Não há uma única resposta correta para essa pergunta. Muitas abordagens, tanto formais quanto heurísticas, podem ser eficazes. Mas uma das respostas mais eficazes e gerais é usar a análise de dados bayesiana. A análise de dados bayesiana pega uma pergunta na forma de um modelo e usa a lógica para produzir uma resposta na forma de distribuições de probabilidade.

Em termos modestos, a análise de dados bayesiana não é mais do que contar os números de maneiras que os dados poderiam acontecer, de acordo com nossas suposições. Coisas que podem acontecer de mais maneiras são mais plausíveis. A teoria das probabilidades é relevante porque a probabilidade é apenas um cálculo para contar. Isso nos permite usar a teoria das probabilidades como uma maneira geral de representar plausibilidade, seja em referência a eventos contáveis no mundo ou a construtos teóricos como parâmetros. O resto segue logicamente. Uma vez que definimos o modelo estatístico, a análise de dados bayesiana força uma maneira puramente lógica de processar os dados para produzir inferência.

O Capítulo 2 explica isso em profundidade. Por enquanto, ajudará ter outra abordagem para comparar. A probabilidade bayesiana é uma abordagem muito geral da probabilidade e inclui, como um caso especial, outra abordagem importante, a abordagem FREQUENTISTA. A abordagem frequentista exige que todas as probabilidades sejam definidas por meio da conexão com as frequências de eventos em amostras muito grandes. Isso leva a incerteza frequentista a ser baseada em uma reamostragem imaginária de dados — se fôssemos repetir a medição muitas e muitas vezes, acabaríamos coletando uma lista de valores que teria algum padrão. Significa também que parâmetros e modelos não podem ter distribuições de probabilidade, apenas as medições podem. A distribuição dessas medições é chamada de DISTRIBUIÇÃO AMOSTRAL. Essa reamostragem nunca é feita e, em geral, nem faz sentido — é absurdo considerar a reamostragem repetida da diversificação de pássaros canoros nos Andes. Como Sir Ronald Fisher, um dos estatísticos frequentistas mais importantes do século XX, colocou:

> [...] as únicas populações que podem ser referidas em um teste de significância não têm realidade objetiva, sendo exclusivamente produto da imaginação do estatístico [...]

Mas em muitos contextos, como em experimentos controlados em estufas, é um dispositivo útil para descrever a incerteza. Qualquer que seja o contexto, é

apenas parte do modelo, uma suposição sobre como os dados seriam sob reamostragem. É tão fantástico quanto a aposta bayesiana de usar a probabilidade para descrever todos os tipos de incerteza, sejam empíricas ou epistemológicas.

Mas essas diferentes atitudes em relação à probabilidade impõem *trade-offs* diferentes. Considere este exemplo simples onde a diferença entre probabilidade bayesiana e frequentista importa. No ano de 1610, Galileu apontou um telescópio primitivo para o céu noturno e se tornou o primeiro ser humano a ver os anéis de Saturno. Bem, ele provavelmente viu um borrão, com alguns borrões menores presos a ele (FIGURA 1.3). Como o telescópio era primitivo, ele realmente não conseguia focar muito bem a imagem. Saturno sempre parecia desfocado. Este é um problema estatístico, de certa forma. Há incerteza sobre a forma do planeta, mas observe que nenhuma incerteza é resultado de variação em medições repetidas. Poderíamos olhar pelo telescópio mil vezes, e ele sempre daria a mesma imagem desfocada (para qualquer posição dada da Terra e de Saturno). Portanto, a distribuição amostral de qualquer medição é constante, porque a medição é determinística — não há nada "aleatório"nisso. A inferência estatística frequentista tem muitos problemas para começar aqui. Em contraste, a inferência bayesiana prossegue como de costume, porque o "ruído"determinístico ainda pode ser modelado usando a probabilidade, desde que não identifiquemos probabilidade com frequência. Como resultado, o campo de reconstrução e processamento de imagens é dominado por algoritmos bayesianos.

Figura 2: Saturno, muito parecido com o que Galileu deve ter visto. A forma verdadeira é incerta, mas não por causa de qualquer variação de amostragem. A teoria das probabilidades ainda pode ajudar.

Em procedimentos estatísticos mais rotineiros, como a regressão linear, essa diferença nos conceitos de probabilidade tem menos efeito. No entanto, é importante perceber que, mesmo quando um procedimento bayesiano e um procedi-

mento frequentista dão exatamente a mesma resposta, nossos golems bayesianos não estão justificando suas inferências com reamostragens repetidas imaginadas. De forma mais geral, os golems bayesianos tratam a "aleatoriedade"como uma propriedade da informação, não do mundo. Nada no mundo real — exceto interpretações controversas da física quântica — é realmente aleatório. Presumivelmente, se tivéssemos mais informações, poderíamos prever tudo exatamente. Nós apenas usamos a aleatoriedade para descrever nossa incerteza diante do conhecimento incompleto. Da perspectiva do nosso golem, o lançamento da moeda é "aleatório", mas na verdade é o golem que é aleatório, não a moeda.

Note que a descrição anterior não invoca as "crenças"ou opiniões subjetivas de ninguém. A análise de dados bayesiana é apenas um procedimento lógico para processamento de informações. Existe uma tradição de usar esse procedimento como uma descrição normativa da crença racional, uma tradição chamada BAYESIANISMO. Mas este livro nem a descreve nem a defende. De fato, argumentarei que nenhuma abordagem estatística, bayesiana ou de outra forma, é por si só suficiente.

> **Repensando: A probabilidade não é unitária.** Deixará alguns leitores desconfortáveis sugerir que há mais de uma maneira de definir "probabilidade". Os conceitos matemáticos não são unicamente corretos? Eles não são. Depois de adotar algum conjunto de premissas, ou axiomas, tudo se segue logicamente em sistemas matemáticos. Mas os axiomas estão abertos ao debate e à interpretação. Portanto, não existe apenas a probabilidade "bayesiana"e a "frequentista", mas também existem diferentes versões da probabilidade bayesiana, baseando-se em diferentes argumentos para justificar a abordagem. Em textos bayesianos mais avançados, você encontrará nomes como Bruno de Finetti, Richard T. Cox e Leonard "Jimmie"Savage. Cada uma dessas figuras está associada a uma concepção um tanto diferente da probabilidade bayesiana. Existem outras. Este livro segue principalmente a interpretação "lógica"de Cox (ou Laplace-Jeffreys-Cox-Jaynes). Esta interpretação é apresentada a partir do próximo capítulo, mas se desdobra totalmente apenas no Capítulo 10.
>
> Como podem prosperar diferentes interpretações da teoria das probabilidades? Por si mesmas, as entidades matemáticas não "significam"necessariamente nada, no sentido de implicação no mundo real. O que significa tirar a raiz quadrada de um número negativo? O que significa tirar um limite quando algo se aproxima do infinito? Esses são conceitos essenciais e rotineiros, mas seus significados dependem do contexto e do analista, das crenças sobre o quão bem a abstração representa a realidade. A matemática não acessa o mundo real diretamente. Portanto, responder a tais perguntas continua sendo um projeto contencioso e divertido, em todos os ramos da matemática aplicada. Portanto, embora todos subscrevam os mesmos axiomas de probabilidade, nem todos concordam em todos os contextos sobre como interpretar a probabilidade.

Antes de passar a descrever as próximas duas ferramentas, vale a pena enfatizar uma vantagem da análise de dados bayesiana, pelo menos quando estudiosos estão aprendendo modelagem estatística. Este livro inteiro poderia ser reescrito para remover qualquer menção ao termo "bayesiano". Em alguns lugares, ficaria mais fácil. Em outros, ficaria muito mais difícil. Mas, tendo ensinado estatística aplicada das duas maneiras, descobri que a estrutura bayesiana apresenta uma vantagem pedagógica distinta: muitas pessoas a acham mais intuitiva. Talvez a melhor evidência disso seja que muitos cientistas interpretam resultados não bayesianos em termos bayesianos, por exemplo, interpretando valores-p ordinários como probabilidades bayesianas *a posteriori* e intervalos de confiança não bayesianos como intervalos bayesianos (você aprenderá sobre probabilidade *a posteriori* e intervalos de confiança nos Capítulos 2 e 3). Até mesmo instrutores de estatística cometem esses erros. Neste sentido, então, os modelos bayesianos levam a interpretações mais intuitivas, aquelas que os cientistas tendem a projetar em resultados estatísticos. O padrão oposto de erro — interpretar uma probabilidade *a posteriori* como um valor-p — parece acontecer apenas raramente.

Nada disso garante que as análises bayesianas serão mais corretas do que as análises não bayesianas. Significa apenas que as intuições do cientista estarão menos comumente em desacordo com a lógica real da estrutura. Isso simplifica alguns dos aspectos do ensino da modelagem estatística.

Repensando: Um pouco de história. A inferência estatística bayesiana é muito mais antiga do que as ferramentas típicas da estatística introdutória, a maioria das quais foi desenvolvida no início do século XX. Versões da abordagem bayesiana foram aplicadas ao trabalho científico no final dos anos 1700 e repetidamente no século XIX. Mas, após a Primeira Guerra Mundial, estatísticos antibayesianos, como Sir Ronald Fisher, conseguiram marginalizar a abordagem. Tudo o que Fisher disse sobre a análise bayesiana (então chamada de *probabilidade inversa*) em seu influente manual de 1925 foi:

> [...] a teoria da probabilidade inversa baseia-se num erro e deve ser totalmente rejeitada.

A análise de dados bayesiana tornou-se cada vez mais aceita dentro da estatística durante a segunda metade do século XX, porque provou não ser baseada em um erro. Deixando toda filosofia de lado, ela funcionava. Começando na década de 1990, novas abordagens computacionais levaram a um rápido aumento na aplicação de métodos bayesianos. Os métodos bayesianos permanecem computacionalmente caros, no entanto. E, à medida que os conjuntos de dados aumentaram de escala — milhões de linhas é comum na análise genômica, por exemplo —, alternativas ou aproximações à inferência bayesiana permanecem importantes e provavelmente sempre o serão.

1.3.2 Comparação de modelos e previsão

A análise de dados bayesiana fornece uma maneira para os modelos aprenderem com os dados. Mas quando há mais de um modelo plausível — e na maioria dos campos maduros deveria haver —, como devemos escolher entre eles? Uma resposta é preferir modelos que façam boas previsões. Essa resposta cria muitas perguntas novas, já que saber qual modelo fará as melhores previsões parece exigir conhecer o futuro. Analisaremos profundamente duas ferramentas relacionadas, nenhuma das quais conhece o futuro: VALIDAÇÃO CRUZADA e CRITÉRIOS DE INFORMAÇÃO. Essas ferramentas visam nos permitir comparar modelos com base na precisão preditiva esperada.

Comparar modelos pela precisão preditiva pode ser útil por si só. E será ainda mais útil porque leva à descoberta de um fato surpreendente: modelos complexos muitas vezes fazem previsões piores do que modelos mais simples. O paradoxo primário da previsão é o OVERFITTING: *O ajuste é fácil; a previsão é difícil.* Dados futuros não serão exatamente iguais aos dados passados e, portanto, qualquer modelo que não esteja ciente desse fato tende a fazer previsões piores do que poderia. E modelos mais complexos tendem a sofrer mais OVERFITTING do que os simples — quanto mais inteligente o golem, mais burras suas previsões. Portanto, se desejamos fazer boas previsões, não podemos julgar nossos modelos simplesmente pelo quão bem eles se ajustam aos nossos dados.

A validação cruzada e os critérios de informação nos ajudam de três maneiras relacionadas. Primeiro, eles fornecem expectativas úteis de precisão preditiva, em vez de um mero ajuste à amostra. Assim, eles comparam modelos onde isso importa. Segundo, eles nos dão uma estimativa da tendência de um modelo de sofrer OVERFITTING nos dados. Isso nos ajudará a entender como modelos e dados interagem, o que, por sua vez, nos ajuda a projetar modelos melhores. Retomaremos esse ponto na próxima seção. Terceiro, a validação cruzada e os critérios de informação podem nos ajudar a identificar observações altamente influentes.

A análise de dados bayesiana vem sendo trabalhada há séculos. Os critérios de informação são comparativamente muito jovens e o campo está evoluindo rapidamente. Muitos estatísticos nunca usaram critérios de informação em um problema aplicado, e não há consenso sobre quais métricas são as melhores e como melhor usá-las. Ainda assim, os critérios de informação já são de uso frequente nas ciências, aparecendo em publicações proeminentes e figurando em debates importantes. O poder deles é frequentemente exagerado, e teremos o cuidado de notar o que eles não podem fazer, bem como o que podem.

> **Repensando: O neandertal em você.** Até mesmo modelos simples precisam de alternativas. Em 2010, o rascunho de um genoma de um Neandertal demonstrou mais sequências de DNA em comum com humanos contemporâneos não africanos do que com africanos. Essa descoberta é consistente com o cruzamento entre neandertais e humanos modernos, à medida que os últimos se dispersaram da África. No entanto, apenas encontrar DNA em comum entre europeus modernos e neandertais não é suficiente para demonstrar o cruzamento.

> Também é consistente com a estrutura antiga no continente africano. Em suma, se os antigos nordestinos da África tivessem sequências de DNA únicas, então neandertais e europeus modernos poderiam possuir essas sequências de um ancestral comum, em vez de por cruzamento direto. Portanto, mesmo no caso aparentemente simples de estimar se neandertais e humanos modernos compartilham DNA único, há mais de uma explicação baseada em processo. A comparação de modelos é necessária.

1.3.3 Modelos multinível

Em um conto apócrifo da cosmologia hindu, diz-se que a Terra repousa nas costas de um grande elefante, que por sua vez fica nas costas de uma enorme tartaruga. Quando perguntado sobre o que a tartaruga está apoiada, diz-se que um guru responde: "é tartaruga até lá embaixo."

Modelos estatísticos não contêm tartarugas, mas eles contêm parâmetros. E os parâmetros sustentam a inferência. Sobre o que os próprios parâmetros se apoiam? Às vezes, em alguns dos modelos mais poderosos, são parâmetros até lá embaixo. O que isso significa é que qualquer parâmetro particular pode ser proveitosamente considerado como um marcador de posição para um modelo ausente. Dado algum modelo de como o parâmetro obtém seu valor, é bastante simples incorporar o novo modelo dentro do antigo. Isso resulta em um modelo com múltiplos níveis de incerteza, cada um alimentando o próximo — um MODELO MULTINÍVEL.

Modelos multinível — também conhecidos como modelos hierárquicos, de efeitos aleatórios, de efeitos variados ou de efeitos mistos — estão se tornando *de rigueur* nas ciências biológicas e sociais. Campos tão diversos quanto testes educacionais e filogenética bacteriana agora dependem de modelos multinível rotineiros para processar dados. Assim como a análise de dados bayesiana, a modelagem multinível não é particularmente nova, mas ela está disponível em computadores pessoais há apenas algumas décadas. E como tais modelos têm uma representação bayesiana natural, eles cresceram lado a lado com a análise de dados bayesiana.

Estaremos interessados em modelos multinível principalmente porque eles nos ajudam a lidar com o OVERFITTING. A validação cruzada e os critérios de informação medem o risco de OVERFITTING e nos ajudam a reconhecê-lo. Mas os modelos multinível realmente fazem algo a respeito. O que eles fazem é explorar um truque estatístico incrível conhecido como AGRUPAMENTO PARCIAL (*partial pooling*) que agrupa informações entre as unidades nos dados para produzir estimativas melhores para todas as unidades. Os detalhes aguardarão até o Capítulo 13.

O agrupamento parcial é a tecnologia-chave, e os contextos nos quais ele é apropriado são diversos. Aqui estão quatro exemplos comuns.

1. *Para ajustar as estimativas para amostragem repetida.* Quando mais de uma observação surge do mesmo indivíduo, local ou época, então os mo-

delos tradicionais de nível único podem nos enganar.

2. *Para ajustar as estimativas para desequilíbrio na amostragem.* Quando alguns indivíduos, locais ou épocas são amostrados mais do que outros, também podemos ser enganados por modelos de nível único.

3. *Para estudar a variação.* Se nossas questões de pesquisa incluem a variação entre indivíduos ou outros grupos dentro dos dados, então os modelos multinível são uma grande ajuda, porque eles modelam a variação explicitamente.

4. *Para evitar tirar médias.* Frequentemente, os pesquisadores tiram a média de alguns dados antecipadamente para construir variáveis para uma análise de regressão. Isso pode ser perigoso, porque a média remove a variação. Portanto, fabrica-se uma falsa confiança. Os modelos multinível nos permitem preservar a incerteza nos valores originais, anteriores à média, e ainda assim usar a média para fazer previsões.

Todos os quatro se aplicam a contextos nos quais o pesquisador reconhece *clusters* ou grupos de medições que podem diferir uns dos outros. Esses *clusters* ou grupos podem ser indivíduos como alunos diferentes, locais como cidades diferentes ou períodos como anos diferentes. Como cada *cluster* pode muito bem ter uma tendência média diferente ou responder de maneira diferente a qualquer tratamento, os dados agrupados frequentemente se beneficiam de serem modelados por um golem que espera essa variação.

Mas o escopo da modelagem multinível é muito maior do que esses exemplos. Diversos tipos de modelos acabam sendo multinível: modelos para dados ausentes (imputação), erro de medição, análise fatorial, alguns modelos de séries temporais, tipos de regressão espacial e de rede e regressões filogenéticas são todos aplicações especiais da estratégia multinível. Compreender o conceito de modelagem multinível pode levar a uma mudança de perspectiva. De repente, modelos de nível único acabam parecendo meros componentes de modelos multinível. A estratégia multinível fornece um princípio de engenharia para nos ajudar a introduzir esses componentes em uma análise particular, exatamente onde achamos que precisamos deles.

Quero convencer o leitor de algo que parece irracional: *a regressão multinível merece ser a forma padrão de regressão.* Trabalhos que não usam modelos multinível deveriam justificar o fato de não usarem uma abordagem multinível. Certamente, alguns dados e contextos não precisam do tratamento multinível. Mas a maioria dos estudos contemporâneos nas ciências sociais e naturais, sejam experimentais ou não, se beneficiaria disso. Talvez o motivo mais importante seja que mesmo os tratamentos bem controlados interagem com aspectos não medidos dos indivíduos, grupos ou populações estudadas. Isso leva a uma variação nos efeitos do tratamento, na qual indivíduos ou grupos variam na forma como respondem à mesma circunstância. Modelos multinível tentam quantificar a extensão dessa variação, bem como identificar quais unidades nos dados responderam de quais maneiras.

Esses benefícios não vêm de graça, no entanto. Ajustar e interpretar modelos multinível pode ser consideravelmente mais difícil do que ajustar e interpretar um modelo de regressão tradicional. Na prática, muitos pesquisadores simplesmente confiam em seus softwares de caixa-preta e interpretam a regressão multinível exatamente como a regressão de nível único. Com o tempo, isso vai mudar. Houve um tempo na estatística aplicada em que mesmo a regressão múltipla comum era considerada de ponta, algo apenas para especialistas mexerem. Em vez disso, os cientistas usavam muitos procedimentos simples, como testes t. Agora, quase todo mundo usa ferramentas multivariadas. O mesmo acabará sendo verdade para os modelos multinível. A cultura acadêmica e o currículo ainda têm algum atraso a recuperar.

> **Repensando: Previsão eleitoral multinível.** Uma das aplicações mais antigas da modelagem multinível é a previsão dos resultados das eleições democráticas. No início dos anos 1960, John Tukey (1915–2000) começou a trabalhar para a *National Broadcasting Company* (NBC) nos Estados Unidos, desenvolvendo modelos de previsão de eleições em tempo real que poderiam explorar diversos tipos de dados: pesquisas, eleições passadas, resultados parciais e resultados completos de distritos relacionados. Os modelos usavam uma estrutura multinível semelhante aos modelos apresentados nos Capítulos 13 e 14. Tukey desenvolveu e usou esses modelos para a NBC até 1978. A previsão eleitoral contemporânea e a agregação de pesquisas continuam sendo um tópico ativo para modelagem multinível.

1.3.4 Modelos causais gráficos

Quando o vento sopra, os galhos balançam. Se você é humano, imediatamente interpreta essa afirmação como causal: O vento faz os galhos se moverem. Mas tudo o que vemos é uma associação estatística. Apenas pelos dados, também poderia ser que o balançar dos galhos fizesse o vento. Essa conclusão parece tola, porque você sabe que as árvores não balançam seus próprios galhos. Um modelo estatístico é um incrível mecanismo de associação. Ele torna possível detectar associações entre causas e seus efeitos. Mas um modelo estatístico nunca é suficiente para inferir a causa, porque o modelo estatístico não faz distinção entre o vento fazer os galhos balançarem e os galhos fazerem o vento soprar. Fatos fora dos dados são necessários para decidir qual explicação está correta.

A validação cruzada e os critérios de informação tentam adivinhar a precisão preditiva. Quando os apresentei acima, descrevi o OVERFITTING como o paradoxo primário da previsão. Agora nos voltamos para um paradoxo secundário da previsão: *Modelos que são causalmente incorretos podem fazer previsões melhores do que aqueles que são causalmente corretos.* Como resultado, focar na previsão pode nos enganar sistematicamente. E embora você possa ter ouvido que experimentos controlados randomizados permitem a inferência causal, esses

riscos também envolvem experimentos randomizados. Ninguém está seguro.

Chamarei a isso de problema de IDENTIFICAÇÃO e o distinguirei cuidadosamente do problema da previsão bruta. Considere dois significados diferentes de "previsão". O mais simples se aplica quando somos observadores externos simplesmente tentando adivinhar o que acontecerá a seguir. Nesse caso, ferramentas como a validação cruzada são muito úteis. Mas essas ferramentas recomendarão alegremente modelos que contêm variáveis de confusão e sugerem relações causais incorretas. Por quê? Relações confundidas são associações reais e podem melhorar a previsão. Afinal, se você olhar para fora e ver galhos balançando, isso realmente prediz o vento. O sucesso da previsão não requer a identificação causal correta. De fato, como você verá mais adiante no livro, as previsões podem realmente melhorar quando usamos um modelo que é causalmente enganoso.

Mas o que acontece quando intervimos no mundo? Agora tudo muda. Agora devemos considerar um segundo significado de "previsão": O que acontecerá quando intervirmos no mundo. Suponha que recrutemos muitas pessoas para subir nas árvores e balançar os galhos. Isso fará vento? Não muito. Muitas vezes, o ponto da modelagem estatística é produzir um entendimento que leve à generalização e aplicação. Nesse caso, precisamos de mais do que apenas boas previsões, na ausência de intervenção. Nós também precisamos de uma compreensão causal precisa. Mas comparar modelos com base na precisão preditiva — ou valores-p ou qualquer outra coisa — não a produzirá necessariamente.

Então o que pode ser feito? O que é necessário é um modelo causal que possa ser usado para projetar um ou mais modelos estatísticos com o propósito de identificação causal. Como mencionei no exemplo de evolução molecular neutra mais cedo neste capítulo, um modelo científico completo contém mais informações do que um modelo estatístico derivado dele. E essa informação adicional contém implicações causais. A maioria dos cientistas faz uso informal dessas implicações. Mas também é possível fazer uso formal delas, demonstrando logicamente quando uma estimativa identifica uma relação causal. Esses métodos formais datam da primeira metade do século XX, mas eles foram estendidos mais recentemente ao estudo da medição, do desenho experimental e da capacidade de generalizar (ou *transportar*) resultados entre as amostras.

E a excelente notícia é que mesmo quando você não tem um modelo causal completo, mas apenas um heurístico indicando quais variáveis influenciam causalmente outras, você ainda pode fazer uso dessas ferramentas lógicas. Essa é a estratégia que usaremos neste livro. Usaremos um MODELO CAUSAL GRÁFICO para representar uma hipótese causal. O modelo causal gráfico mais simples é um GRAFO ACÍCLICO DIRECIONADO, geralmente chamado de DAG. Os DAGs são heurísticos — eles não são modelos estatísticos detalhados. Mas eles nos permitem deduzir quais modelos estatísticos podem fornecer inferências causais válidas, assumindo que o DAG seja verdadeiro. Você não precisa entender isso agora. Os capítulos posteriores constroem DAGs por meio de exemplos.

Mas de onde vem o próprio DAG? A terrível verdade sobre a inferência estatística é que sua validade depende de informações fora dos dados. Nós requeremos um modelo causal com o qual projetar tanto a coleta de dados quanto a estrutura de nossos modelos estatísticos. Mas a construção de modelos

causais não é um esforço puramente estatístico, e a análise estatística nunca pode verificar todas as nossas suposições. Nunca haverá um golem que aceite dados nus e retorne um modelo confiável das relações causais entre as variáveis. Teremos apenas que continuar fazendo ciência.

> **Repensando: Salada causal.** A inferência causal requer um modelo causal que seja separado do modelo estatístico. Os dados não são suficientes. Toda filosofia concorda quanto a isso. As respostas, no entanto, são diversas. A resposta mais conservadora é declarar a "causação"como um doce mental improvável, como debater a natureza da vida após a morte. Um pouco menos conservador é insistir que a causa só pode ser inferida sob condições estritas de randomização e controle experimental. Isso seria muito limitante. Muitas questões científicas nunca podem ser estudadas experimentalmente — a evolução humana, por exemplo. Muitas outras poderiam, em princípio, ser estudadas experimentalmente, mas seria antiético fazê-lo. E muitos experimentos são na verdade apenas tentativas de controle — pacientes nem sempre tomam sua medicação.
>
> Mas a abordagem que domina em muitas partes da biologia e das ciências sociais é, em vez disso, a SALADA CAUSAL. Salada causal significa jogar várias variáveis de "controle"em um modelo estatístico, observar mudanças nas estimativas e, em seguida, contar uma história sobre a causalidade. A salada causal parece fundada na noção de que apenas variáveis omitidas podem nos induzir em erro sobre a causação. Mas variáveis *incluídas* podem nos confundir com a mesma facilidade. Ao misturar uma salada causal, um modelo que faz boas previsões ainda pode enganar sobre a causação. Se usarmos o modelo para planejar uma intervenção, ele errará tudo. Haverá exemplos em capítulos posteriores.

1.4 Resumo

Este primeiro capítulo argumentou a favor de um repensar da filosofia estatística e científica popular. Em vez de escolher entre várias ferramentas de caixa-preta para testar hipóteses nulas, devemos aprender a construir e analisar múltiplos modelos não nulos de fenômenos naturais. Para apoiar este objetivo, o capítulo introduziu a inferência bayesiana, a comparação de modelos, os modelos multinível e os modelos causais gráficos. O restante do livro está organizado em quatro partes interdependentes.

1. Os Capítulos 2 e 3 são fundamentais. Eles introduzem a inferência bayesiana e as ferramentas básicas para realizar cálculos bayesianos. Eles avançam bem devagar e enfatizam uma interpretação puramente lógica da teoria das probabilidades.

2. Os próximos quatro capítulos, do 4 ao 9, constroem a regressão linear múltipla como uma ferramenta bayesiana. Esta ferramenta apoia a in-

ferência causal, mas apenas quando analisamos modelos causais separados que nos ajudam a determinar quais variáveis incluir. Estes capítulos enfatizam a plotagem de resultados em vez de tentar interpretar estimativas de parâmetros individuais. Problemas de complexidade do modelo — OVERFITTING — também aparecem com destaque. Portanto, você também terá uma introdução à teoria da informação e à comparação formal de modelos no Capítulo 7.

3. A terceira parte do livro, Capítulos 9 a 12, apresenta modelos lineares generalizados de vários tipos. O Capítulo 9 introduz o método de Monte Carlo via cadeias de Markov (*Markov chain Monte Carlo*), usado para ajustar os modelos nos capítulos posteriores. O Capítulo 10 introduz a entropia máxima como um procedimento explícito para nos ajudar a projetar e interpretar esses modelos. Em seguida, os Capítulos 11 e 12 detalham os próprios modelos.

4. A última parte, Capítulos 13 a 16, aborda modelos multinível, bem como modelos especializados que lidam com erros de medição, dados ausentes e correlação espacial. Este material é bastante avançado, mas prossegue da mesma maneira mecanicista que o material anterior. O Capítulo 16 afasta-se do restante do livro ao implantar modelos que não são do tipo linear generalizado, mas sim modelos teóricos expressos diretamente como modelos estatísticos.

O capítulo final, Capítulo 17, retorna a algumas das questões levantadas neste primeiro.

No final de cada capítulo, há problemas práticos que variam do fácil ao difícil. Esses problemas ajudam você a testar sua compreensão. Os mais difíceis expandem o material, introduzindo novos exemplos e obstáculos.